

社交媒体虚假新闻检测

——基于 LSTM/Bi-LSTM 与传统机器学习基线的系统性对比研究

韩兆津¹ 初新鹏¹ 孙娅纯¹ 赵思羽¹

Abstract—虚假新闻在社交媒体平台上的大规模扩散已成为重要的社会问题。本文以公开的 ISOT Fake News 数据集 (44,898 条新闻) 为研究对象, 构建了一套完整的端到端虚假新闻自动检测系统, 并对五种检测方法进行系统性对比: 三种基于 TF-IDF 特征的传统机器学习基线 (Logistic Regression, Linear SVM, Random Forest) 与两种基于词嵌入序列的深度学习模型 (LSTM, Bi-LSTM)。实验结果表明, Linear SVM 综合性能最优 ($F_1 = 0.9981$, 训练仅需 2.7 s); Bi-LSTM 在 6,000 条均衡子集上取得 $F_1 = 0.9980$, 且较单向 LSTM ($F_1 = 0.9047$) 提升约 9.3 个百分点, 充分验证了双向上下文建模对文本分类任务的显著增益。此外, 本文揭示了 ISOT 数据集存在的来源风格强相关问题, 并就跨域泛化、多模态融合与预训练模型扩展提出了改进方向。

Index Terms—虚假新闻检测, LSTM, Bi-LSTM, 文本分类, TF-IDF, 社交媒体, 自然语言处理

I. 项目背景与意义

A. 研究背景

随着社交媒体的飞速发展, 信息的产生与传播速度达到了前所未有的程度。在 Twitter、Facebook、微博等平台上, 每天有数以亿计的内容被生成和分享。然而, 这一开放、低门槛的传播环境也成为虚假新闻 (Fake News) 滋生与扩散的温床。虚假新闻往往具有标题党、情绪化、煽动性等特征, 极易引发误导, 进而影响公众认知、社会稳定甚至国家安全 [1]。特别是在重大社会事件 (如选举、公共卫生危机) 期间, 虚假信息传播可能造成严重的社会危害。因此, 如何利用人工智能与自然语言处理技术对海量信息进行自动化的真伪鉴别, 已成为学术界与工业界共同关注的研究热点 [2]。

B. 研究意义

本项目以 ISOT Fake News Dataset 为研究对象, 采用循环神经网络 (LSTM 与 Bi-LSTM) 作为核心建模工具, 同时与传统机器学习方法 (Logistic Regression, SVM, Random Forest) 进行对比, 系统地探索文本类虚假新闻检测的可行性, 具体目标包括:

- 1) 构建端到端的虚假新闻检测流水线: 数据探索 → 文本预处理 → 模型训练 → 评估对比 → 在线推理;
- 2) 通过 LSTM 与 Bi-LSTM 的对比, 分析双向上下文建模对文本分类的增益;
- 3) 通过深度学习与传统方法的对比, 评估不同方案的性能与代价权衡;
- 4) 输出可复用的检测原型与可视化报告, 为后续工业化部署提供参考。

II. 数据集介绍

A. 数据来源与基本信息

本项目使用公开的 ISOT Fake News Dataset [3], 包含:

- **True.csv**: 共 21,417 条真实新闻, 主要来自 Reuters 等权威媒体;
- **fake.csv**: 共 23,481 条虚假新闻, 来自被 PolitiFact、Wikipedia 等机构标记为不可靠的网站。

两类样本合计 44,898 条, 类别分布相对均衡 (真实约 47.7%, 虚假约 52.3%)。每条样本包含四个字段, 如表 I 所示。

TABLE I: 数据集字段说明

字段名	类型	含义
title	string	新闻标题
text	string	新闻正文
subject	string	主题分类 (politics、worldnews 等)
date	string	发布日期

B. 探索性数据分析

1) 类别与主题分布: 类别分布相对均衡, 不存在严重的不平衡问题, 因此后续模型评估可直接采用准确率配合 F_1 等指标。图 1 展示了样本数量与比例。主题分布上, 真实新闻集中在 politicsNews 与 worldnews 两个主题; 虚假新闻则覆盖 News、politics、left-news 等多个细分主题, 来源更加分散, 如图 2 所示。




Fig. 1: 样本数量与类别比例




Fig. 2: 真实/虚假新闻的主题分布

2) 文本长度统计: 从词数维度看, 虚假新闻的标题平均含 14.7 个词, 显著长于真实新闻的 10.0 个词, 与其倾向使用煽动性长标题 (如”BREAKING:”、”Donald Trump...””) 的特征一致。正文长度两类相差不大 (真实约 386 词, 虚假约 423 词), 但虚假新闻方差更大, 存在大量异常长文本。图 3 展示了词数分布直方图与箱线图。




Fig. 3: 标题与正文词数分布及箱线图

3) 高频词与时间分布: 通过去除停用词后的词频统计, 两类新闻在词汇使用上存在明显偏差: 真实新闻高频词以”said”、”government”、”states”等中性客观的报道用词为主; 虚假新闻则更频繁出现”trump”、”people”、”hillary”等情绪化或人物聚焦的词汇, 如图 4 所示。




Fig. 4: 真实与虚假新闻 Top-20 高频词对比

时间维度上, 数据集主要覆盖 2015–2018 年, 虚假新闻在 2016 年美国大选前后出现显著高峰, 如图 5 所示。




Fig. 5: 新闻发布时间分布

III. 数据预处理

A. 文本清洗

原始文本中混杂大量噪声, 本项目采用以下六步流水线进行统一清洗:

- 1) 统一小写化, 消除大小写差异;
- 2) 正则去除 URL 与 HTML 标签;
- 3) 移除 @ 用户名, 保留 #hashtag 文字部分;
- 4) 仅保留英文字母与空格, 删除数字与标点;
- 5) 折叠连续空白, 切分为词;
- 6) 去除长度小于 3 的短句及英文停用词, 过滤后剔除少于 5 词的极短样本 (共 11 条)。

此外, 将 title 与 text 拼接为单一文本字段, 使模型同时利用标题与正文信号。清洗后有效样本为 44,887 条。

B. 数据划分

采用分层抽样按 70% / 15% / 15% 划分训练集、验证集与测试集, 保证各集类别比例一致, 结果如表 II 所示。

TABLE II: 数据集划分结果

集合	样本数	占比
训练集 (Train)	31,418	70.0%
验证集 (Validation)	6,735	15.0%
测试集 (Test)	6,734	15.0%
合计	44,887	100.0%

C. 文本数值化

为兼顾基线与深度模型, 构建两套特征:

- **TF-IDF (基线)**: 1-2 元 N-gram, max_features=20,000, min_df=3, max_df=0.95, sublinear_tf=True;
- **整数序列 (LSTM)**: 训练集词表 20,000 词 (<pad>=0, <unk>=1), 截断/填充至固定长度 $T = 300$ 。

IV. 模型方法

A. 整体方案

本项目共训练并对比 5 个模型, 分为两大类:

- **基线模型** (TF-IDF 特征): Logistic Regression、Linear SVM、Random Forest;
- **深度学习模型** (词嵌入序列): LSTM 与 Bi-LSTM。

B. 基线模型

三个基线模型均使用 scikit-learn 实现, 主要超参如表 III 所示。

TABLE III: 基线模型关键超参

模型	关键超参
Logistic Regression	$C=1.0$, solver=liblinear, max_iter=1000
Linear SVM	$C=1.0$, max_iter=2000
Random Forest	n_estimators=100, max_depth=None

C. LSTM 与 Bi-LSTM

1) *LSTM* 单元原理: 长短期记忆网络 (LSTM) [4] 通过门控机制缓解梯度消失问题。给定时刻 t 的输入 $\mathbf{x}_t$ 与前一时刻隐状态 $\mathbf{h}_{t-1}$, 各门计算如下:

$$\mathbf{i}_t = \sigma(\mathbf{W}_{xi}\mathbf{x}_t + \mathbf{W}_{hi}\mathbf{h}_{t-1} + \mathbf{b}_i) \quad (1)$$

$$\mathbf{f}_t = \sigma(\mathbf{W}_{xf}\mathbf{x}_t + \mathbf{W}_{hf}\mathbf{h}_{t-1} + \mathbf{b}_f) \quad (2)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_{xo}\mathbf{x}_t + \mathbf{W}_{ho}\mathbf{h}_{t-1} + \mathbf{b}_o) \quad (3)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_{xg}\mathbf{x}_t + \mathbf{W}_{hg}\mathbf{h}_{t-1} + \mathbf{b}_g) \quad (4)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (5)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (6)$$

其中 $\sigma(\cdot)$ 为 Sigmoid 函数, $\odot$ 为逐元素乘积。输入门 (式 1) 控制新信息的写入量; 遗忘门 (式 2) 决定历史记忆的保留比例; 输出门 (式 3) 调节隐状态对外的输出强度。

2) *Bi-LSTM*: 单向 LSTM 仅利用位置 t 之前的上下文。双向 LSTM (Bi-LSTM) [5] 同时部署前向 LSTM 与反向 LSTM, 最终表示为两方向末时刻隐状态的拼接:

$$\mathbf{h} = [\vec{\mathbf{h}}_T \parallel \overleftarrow{\mathbf{h}}_1] \in \mathbb{R}^{2H} \quad (7)$$

其中 H 为单方向隐层维度, $\parallel$ 表示向量拼接。

3) 分类器网络结构: 完整的文本分类网络从输入到输出依次为:

$$\underbrace{\text{Embedding}(V, d)}_{\text{词嵌入}} \rightarrow \underbrace{\text{LSTM/Bi-LSTM}(H)}_{\text{序列建模}} \rightarrow \underbrace{\text{Dropout}(0.3)}_{\text{正则化}} \rightarrow \underbrace{\text{Linear}(H \rightarrow 1)}_{\text{输出层}} \rightarrow \hat{y}$$

其中词表大小 $V=20,000$, NumPy 版本超参设置为 $d=32$, $H=32$, $T=120$, $\text{batch}=32$, $\text{epochs}=4$, Adam ($\text{lr}=5 \times 10^{-3}$, 梯度裁剪阈值 $=5.0$), 训练集随机均衡抽取 6,000 条。训练损失采用二元交叉熵:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)] \quad (8)$$

D. 评估指标

由于类别基本均衡, 采用以下五个指标: Accuracy (准确率)、Precision (精确率)、Recall (召回率)、 F_1 -Score (调和平均) 以及 AUC (ROC 曲线下面积), 其中:

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (9)$$

V. 实验结果与分析

A. 基线模型结果

三个基线模型在测试集上的表现如表 IV 所示。

TABLE IV: 基线模型测试集性能对比

模型	Acc	Prec	Rec	F_1	AUC	耗时
LogReg	0.9923	0.9880	0.9960	0.9919	0.9994	2.48 s
Linear SVM	0.9982	0.9978	0.9984	0.9981	0.9999	2.67 s
RandomForest	0.9978	0.9972	0.9981	0.9977	1.0000	51.1 s

三个基线模型均超过 99% 准确率, 表明在 ISOT 数据集上真实与虚假新闻在词汇层面存在非常显著分布差异。Linear SVM 综合性能最优 ($F_1=0.9981$, $\text{AUC}=0.9999$), 且训练仅需 2.7s, 显著优于 Random Forest (训练约 51s)。图 6 展示了混淆矩阵, 图 7 展示了 ROC 曲线。




Fig. 6: 三个基线模型的混淆矩阵




Fig. 7: 三个基线模型的 ROC 曲线对比

B. LSTM 与 Bi-LSTM 结果

深度学习模型在测试集上的表现如表 V 所示。

TABLE V: 深度学习模型测试集性能对比

模型	Acc	Prec	Rec	F_1	AUC
LSTM	0.9037	0.8955	0.9140	0.9047	0.9489
Bi-LSTM	0.9980	0.9987	0.9973	0.9980	0.9995

单向 LSTM 取得 $F_1=0.9047$, 而 Bi-LSTM 大幅提升至 $F_1=0.9980$, 提升幅度约 9.3 个百分点。Bi-LSTM 引入反向通路后, 模型能够联合前后文信号, 有效识别虚假新闻典型的写作模式 (如标题党句式、情绪化结尾)。图 8 为训练/验证曲线, 图 9 为混淆矩阵。




Fig. 8: LSTM 与 Bi-LSTM 训练/验证损失与准确率曲线




Fig. 9: LSTM 与 Bi-LSTM 混淆矩阵

从训练曲线可以观察到，Bi-LSTM 仅在第 1 个 epoch 就将验证准确率推至 99.8%，而单向 LSTM 在 4 个 epoch 后仍在 91% 附近震荡，进一步印证了上述结论。

C. 综合对比

五个模型的完整性能汇总如表 VI、图 10 与图 11 所示。

TABLE VI: 所有模型综合性能汇总

模型	类别	Acc	Prec	Rec	F_1	AUC
LogReg	Baseline	0.9923	0.9880	0.9960	0.9919	0.9994
Linear SVM	Baseline	0.9982	0.9978	0.9984	0.9981	0.9999
RandomForest	Baseline	0.9978	0.9972	0.9981	0.9977	1.0000
LSTM	Deep	0.9037	0.8955	0.9140	0.9047	0.9489
Bi-LSTM	Deep	<u>0.9980</u>	0.9987	0.9973	<u>0.9980</u>	0.9995

粗体：全局最优；下划线：深度模型最优。

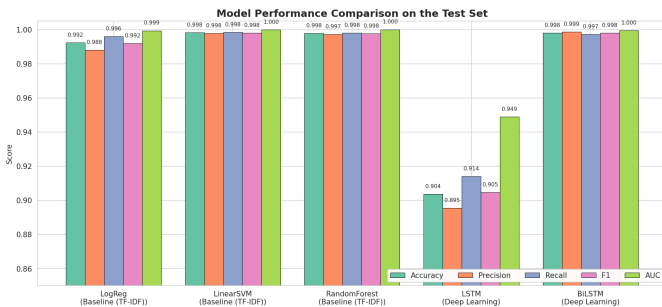


Fig. 10: 五个模型综合性能对比（柱状图）




Fig. 11: 模型性能雷达图

D. 结果讨论

数据集可分性问题。 ISOT 数据集的真实新闻几乎全部来自 Reuters，含有固定的报道句式（如“WASHINGTON (Reuters) -”），而虚假新闻来源分散且写作风格各异。因此即使最简单的线性模型也能达到 99% 以上准确率，模型很可能学到了来源风格而非真伪本质。

效率与性能权衡。 Linear SVM 以 $F_1=0.9981$ 、2.7s 训练时间成为工程性价比最优方案。Bi-LSTM 的训练成本远高于 SVM，但其连续语义表示在迁移学习、域适应场景下更具优势，且可方便地扩展到 Attention、Transformer 等更复杂的架构。

双向建模的重要性。 单向 LSTM 与 Bi-LSTM 近 10 个百分点的差距表明：在序列长度较长 ($T=120$ 词) 且模型规模较小时，单向信息流难以充分利用后文上下文，双向结构是文本分类任务中的重要工程实践。

VI. 系统实现

A. 项目结构

系统代码按模块化组织，核心文件包括：01_edu.py (数据探索)、02_preprocess.py (文本清洗与序列化)、03_train_baseline.py (TF-IDF 基线)、04_train_lstm.py (NumPy 版 LSTM/Bi-LSTM)、04b_train_lstm_pytorch.py (PyTorch 版)、05_compare.py (模型对比图)、06_predict.py (命令行推理)、app.py (Gradio Web 界面)。模型权重保存在 results/，可视化图表在 figures/。

B. 运行指南

依次执行以下命令即可复现全部实验：

```
python src/01_edu.py
python src/02_preprocess.py
python src/03_train_baseline.py
python src/04_train_lstm.py
python src/05_compare.py
python src/06_predict.py --text "..."
```


C. 推理 Demo

06_predict.py 加载最佳基线模型 (Linear SVM), 支持命令行单条推理与交互式输入, 推理耗时在毫秒级。示例输出如下:

```
$ python src/06_predict.py \
  --text "WASHINGTON (Reuters) - ..."
Prediction: Real (confidence ~0.8758)

$ python src/06_predict.py \
  --text "BREAKING: Hillary Clinton..."
Prediction: Fake (confidence ~0.8849)
```

D. Web 交互界面

系统提供基于 Gradio [8] 的可视化 Web 界面 (app.py), 复用已训练的 Linear SVM 与 TF-IDF 向量化器 (best_baseline.pkl), 支持用户在浏览器中粘贴新闻文本并即时获得检测结果与置信度分数。界面内置 4 条典型样例, 推理耗时毫秒级, 预处理流程与训练阶段完全一致。启动命令: `pip install gradio && python app.py`, 访问地址为 <http://127.0.0.1:7860>。

VII. 总结与展望

A. 工作总结

本项目以 ISOT Fake News 数据集为基础, 完成了从数据探索、文本预处理、模型训练到综合对比的端到端虚假新闻检测系统, 主要贡献包括:

- 1) 完成了 5 维度的 EDA, 揭示了类别分布、文本长度、关键词与时间分布的统计规律;
- 2) 设计并实现了完整的文本清洗与序列化流水线, 同时支持 TF-IDF 与 Embedding 两种特征空间;
- 3) 对比了 5 种模型 (LR / LinearSVM / RF / LSTM / Bi-LSTM), 以 5 个量化指标全面评估;
- 4) 用 NumPy 从零实现了 LSTM 与 Bi-LSTM (含完整 BPTT 与 Adam 优化器), 加深了对门控机制的理解; 同时提供 PyTorch 工业级实现;
- 5) 在该数据集上, Linear SVM 与 Bi-LSTM 均取得 $\approx 99.8\%$ 的 F_1 , 推理 demo 可在毫秒级给出预测。

B. 不足与改进方向

- **数据多样性:** 引入 LIAR [6]、FakeNewsNet 等多源数据集, 进行跨域泛化测试;
- **模型扩展:** 引入 Attention 机制与 BERT [7]/RoBERTa 预训练模型;
- **多模态融合:** 引入图片、视频、社交转发图等多模态信息;
- **可解释性:** 结合 LIME/SHAP 与注意力可视化, 给出判定依据;
- **对抗鲁棒性:** 评估模型在同义改写、添加噪声等对抗样本下的稳定性。

致谢

感谢 ISOT Lab 公开发布 Fake News Dataset, 使本研究得以开展。

REFERENCES

- [1] K. Shu, A. Sliva, S. Wang, J. Tang, and H. Liu, "Fake news detection on social media: A data mining perspective," *ACM SIGKDD Explorations Newsletter*, vol. 19, no. 1, pp. 22–36, 2017.
- [2] X. Zhou and R. Zafarani, "A survey of fake news: Fundamental theories, detection methods, and opportunities," *ACM Computing Surveys*, vol. 53, no. 5, pp. 1–40, 2020.
- [3] H. Ahmed, I. Traore, and S. Saad, "Detection of online fake news using N-gram analysis and machine learning techniques," in *Proc. Int. Conf. Intelligent, Secure, and Dependable Systems in Distributed and Cloud Environments (ISDDC)*, Vancouver, Canada, 2017, pp. 127–138.
- [4] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [5] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Trans. Signal Process.*, vol. 45, no. 11, pp. 2673–2681, 1997.
- [6] W. Y. Wang, "'Liar, liar pants on fire': A new benchmark dataset for fake news detection," in *Proc. 55th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, Vancouver, Canada, 2017, pp. 422–426.
- [7] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. Conf. North American Chapter Assoc. Comput. Linguistics (NAACL)*, Minneapolis, MN, USA, 2019, pp. 4171–4186.
- [8] A. Abid, A. Abdalla, A. Abid, D. Khan, A. Alfozan, and J. Zou, "Gradio: Hassle-free sharing and testing of ML models in the wild," *arXiv preprint arXiv:1906.02569*, 2019.